

# APRENDIZAJE AUTOMÁTICO

## Memoria de SVM

- Fabián Scherle Carboneres
- Lishuang Sun (María)

**1. En el subdirectorio data/mini se encuentran dos pequeños conjuntos de datos de entrenamiento en dos dimensiones: (trSep.dat, trSeplabels.dat) y (tr.dat, trlabels.dat). El primero es linealmente separable (no es necesario kernel) y el segundo no. Para cada uno de estos conjuntos4:**

- **Obtén los SVM sin kernel (es decir, kernel tipo lineal). Para simular la optimización estándar del caso separable basta usar un valor grande de C (C = 1000).**
- **Determina:**
  - a) **los multiplicadores de Lagrange, asociados a cada dato de entrenamiento.**
  - b) **los vectores soporte.**
  - c) **el vector de pesos y umbral de la función discriminante lineal.**
  - d) **el margen correspondiente.**
- **Calcula los parámetros de la frontera lineal (recta) de separación;**
- **Representa gráficamente los vectores de entrenamiento, marcando los que son vectores soporte, y la recta separadora correspondiente.**

**Ademas, para el conjunto no-separable utilizando diversos valores relevantes de C:**

- **Determina los valores de tolerancia de margen, , asociados a cada dato de entrenamiento.**
- **Marca los vectores soporte “erróneos” en la representación grafica.**

### Datos linealmente separables:

```
load data/mini/trSep.dat
load data/mini/trSeplabels.dat
res = svmtrain(xl, X, “-t 0 -c 1000”);
```

**a)**

```
abs(res.sv_coef) = [0.87472, 0.74989, 1.62461]
```

Utilizamos *abs* debido a que la clase 2 se interpreta como -1 y en *sv\_coef* se tiene la multiplicación de la  $\alpha$  por la etiqueta de clase.

**b)**

```
full(res.SVs) = [1 4; 4 2; 3 4]
```

**c)**

```
theta = res.sv_coef' * res.SVs = [-0.99955 -1.49978]
```

**Escogemos cualquier vector soporte tal que  $0 < \alpha < C$ . Para la muestra 1:**

```
theta0 = sign(res.sv_coef(1)) - theta*res.SVs(1,:) = 7.9987
```

**d)**

$$\text{Margen} = 2 / \text{norm}(\text{theta}) = 1.1097$$

**Frontera lineal de separación:**  $7.9987 - 0.99955 * x_1 - 1.49978 * x_2 = 0$

$x_1 = [0:7];$

$x_2 = -\text{theta}(1)/\text{theta}(2)*x_1 - \text{theta}(0)/\text{theta}(2);$

**Ecuaciones Margen:**

$$7.9987 - 0.99955 * x_1 - 1.49978 * x_2 = +1$$


$$7.9987 - 0.99955 * x_1 - 1.49978 * x_2 = -1$$

$$x_3 = -\text{theta}(1)/\text{theta}(2)*x_1 - \text{theta}(0)/\text{theta}(2) - 1/\text{theta}(2);$$

$$x_4 = -\text{theta}(1)/\text{theta}(2)*x_1 - \text{theta}(0)/\text{theta}(2) + 1/\text{theta}(2);$$

**Representación gráfica:**

`plot(X(xl==1),X(xl==1,2),"sr",X(xl==2,1),X(xl==2,2),"ob", X(res.sv_indices,1),  
X(res.sv_indices,2),"x",x1,x2,"-k",x1,x3,"-g",x1,x4,"-g"); axis([0 7 0 7])`



**Datos linealmente no separables:**

**(falta dibujar las rectas separadoras y marcar los SV erróneos)**

`load data/mini/tr.dat`

`load data/mini/trlabels.dat`

**C = 1**

`res = svmtrain(xl, X, "-t 0 -c 1")`

**a)**

`abs(res.sv_coef) = [0.65306, 0.73472, 1, 1, 0.38778, 1]`

**b)**

`full(res.SVs) = [1 4; 4 2; 4 4; 3 4; 3 5; 4 3]`

**c)**

`theta = res.sv_coef' * res.SVs = [-0.57139 -0.85722]`

`theta0 = sign(res.sv_coef(1)) - theta*res.SVs(1,:)' = 5.0003`

**d)**

$$\text{Margen} = 2/\text{norm}(\text{theta}) = 1.9414$$

**Frontera lineal de separación:**  $5.0003 - 0.57139 * x_1 - 0.85722 * x_2 = 0$

```
x1 = [0:7];
x2 = -theta(1)/theta(2)*x1 - theta0/theta(2);
```

#### Ecuaciones Margen:

```
5.0003 - 0.57139 * x1 - 0.85722 * x2 = +1
5.0003 - 0.57139 * x1 - 0.85722 * x2 = -1
x3 = -theta(1)/theta(2)*x1 - theta0/theta(2) - 1/theta(2);
x4 = -theta(1)/theta(2)*x1 - theta0/theta(2) + 1/theta(2);
```

#### Tolerancia de margen:


```
T = [];
for n=1:rows(res.sv_coef)
if abs(res.sv_coef(n)) == 1
T(n) = 1 - sign(res.sv_coef(n))*(theta*X(res.sv_indices(n,:))'+theta0');
else T(n) = 0;
endif
endfor
n=3 → ζ9 = 1.171418
n=4 → ζ5 = 0.85722
n=6 → ζ10 = 1.14304
```

Las demás muestras tienen ζ<sub>n</sub> = 0.

Aquellos vectores cuyas tolerancias de margen ζ son diferente de 0, tienen error de clasificación si la tolerancia de margen ζ > 1 y dentro del margen si ζ ≤ 1. Por lo tanto los vectores soporte erróneos son las muestras 5, 9 y 10.

#### Representación gráfica:

```
plot(X(xl==1),X(xl==1,2),"or",X(xl==2,1),X(xl==2,2),"ob", X(res.sv_indices,1),
X(res.sv_indices,2),"xb",x1,x2,"-k",x1,x3,"-g",x1,x4,"-g",X([5,9,10],1),
X([5,9,10],2),"xr"); axis([0 7 0 7])
```



#### C = 10

```
res = svmtrain(xl, X, "-t 0 -c 10")
```

a)

```
abs(res.sv_coef) = [3.3749, 5.7498, 10, 9.1247, 10]
```

b)

```
full(res.SVs) = [1 4; 4 2; 4 4; 3 4; 4 3]
```

c)

```
theta = res.sv_coef' * res.SVs = [-1 -1.4996]
theta0 = sign(res.sv_coef(1)) - theta*res.SVs(1,:) = 7.9986
```

d)

```
Margen = 2/norm(theta) = 1.1096
```

**Frontera lineal de separación:**  $7.9986 - 1 * x_1 - 1.4996 * x_2 = 0$

```
x1 = [0:7];
x2 = -theta(1)/theta(2)*x1 - theta0/theta(2);
```

#### Ecuaciones Margen:

```
7.9986 - 1 * x1 - 1.4996 * x2 = +1
7.9986 - 1 * x1 - 1.4996 * x2 = -1
x3 = -theta(1)/theta(2)*x1 - theta0/theta(2) - 1/theta(2);
x4 = -theta(1)/theta(2)*x1 - theta0/theta(2) + 1/theta(2);
```

#### Tolerancia de margen:


```
T = [];
for n=1:rows(res.sv_coef)
if abs(res.sv_coef(n)) == 10
T(n) = 1 - sign(res.sv_coef(n))*(theta*X(res.sv_indices(n,:))'+theta0');
else T(n) = 0;
endif
endfor
n=3 →  $\zeta_9 = 3$ 
n=5 →  $\zeta_{10} = 0.49965$ 
```

Las demás muestras tienen  $\zeta_n = 0$ .

Aquellos vectores cuyas tolerancias de margen  $\zeta$  son diferente de 0, tienen error de clasificación si la tolerancia de margen  $\zeta > 1$  y dentro del margen si  $\zeta \leq 1$ . Por lo tanto los vectores soporte erróneos son las muestras 9 y 10.

#### Representación gráfica:

```
plot(X(xl==1),X(xl==1,2),"or",X(xl==2,1),X(xl==2,2),"ob", X(res.sv_indices,1),
X(res.sv_indices,2),"xb",x1,x2,"-k",x1,x3,"-g",x1,x4,"-g",X([9,10],1), X([9,10],2),"xr");
axis([0 7 0 7])
```



#### C = 100

```
res = svmtrain(xl, X, "-t 0 -c 100")
```

a)

```
abs(res.sv_coef) = [25.875, 50.750, 100, 76.625, 100]
```

b)

```
full(res.SVs) = [1 4; 4 2; 4 4; 3 4; 4 3];
```

c)

```
theta = res.sv_coef' * res.SVs = [-0.99955 -1.49978]
theta0 = sign(res.sv_coef(1)) - theta*res.SVs(1,:) = 7.9987
```

d)

```
Margen = 2/norm(theta) = 1.1097
```

**Frontera lineal de separación:**  $7.9987 - 0.99955 \cdot x_1 - 1.49978 \cdot x_2 = 0$

```
x1 = [0:7];
x2 = -theta(1)/theta(2)*x1 - theta0/theta(2);
```

#### Ecuaciones Margen:

```
7.9987 - 0.99955*x1 - 1.49978*x2 = +1
7.9987 - 0.99955*x1 - 1.49978*x2 = -1
x3 = -theta(1)/theta(2)*x1 - theta0/theta(2) - 1/theta(2);
x4 = -theta(1)/theta(2)*x1 - theta0/theta(2) + 1/theta(2);
```

#### Tolerancia de margen:

```
T = [];
for n=1:rows(res.sv_coef)
if abs(res.sv_coef(n)) == 100
T(n) = 1 - sign(res.sv_coef(n))*(theta*X(res.sv_indices(n,:))'+theta0');
else T(n) = 0;
endif
endfor
```

$n=3 \rightarrow \zeta_9 = 2.99866$


$n=5 \rightarrow \zeta_{10} = 0.50112$

Las demás muestras tienen  $\zeta_n = 0$ .

Aquellos vectores cuyas tolerancias de margen  $\zeta$  son diferente de 0, tienen error de clasificación si la tolerancia de margen  $\zeta > 1$  y dentro del margen si  $\zeta \leq 1$ . Por lo tanto los vectores soporte erróneos son las muestras 9 y 10.

#### Representación gráfica:

```
plot(X(xl==1),X(xl==1,2),"or",X(xl==2,1),X(xl==2,2),"ob", X(res.sv_indices,1),
X(res.sv_indices,2),"xb",x1,x2,"-k",x1,x3,"-g",x1,x4,"-g",X([9,10],1), X([9,10],2),"xr");
axis([0 7 0 7])
```



#### C = 1000

```
res = svmtrain(xl, X, "-t 0 -c 1000")
```

a)

```
abs(res.sv_coef) = [250.87, 500.75, 1000, 751.62, 1000]
```

b)

```
full(res.SVs) = [1 4; 4 2; 4 4; 3 4; 4 3]
```

c)

```
theta = res.sv_coef' * res.SVs = [-0.99955 -1.49977]
```

```
theta0 = sign(res.sv_coef(1)) - theta*res.SVs(1,:) = 7.9986
```

d)

**Margen** =  $2/\text{norm}(\text{theta}) = 1.1097$

**Frontera lineal de separación:**  $7.9986 - 0.99955 * x1 - 1.49977 * x2 = 0$

```
x1 = [0:7];
x2 = -theta(1)/theta(2)*x1 - theta0/theta(2);
```

### Ecuaciones Margen:

$$7.9986 - 0.99955 * x_1 - 1.49977 * x_2 = +1$$

$$7.9986 - 0.99955 * x_1 - 1.49977 * x_2 = -1$$

$$x_3 = -\theta(1)/\theta(2)*x_1 - \theta(0)/\theta(2) - 1/\theta(2);$$

$$x_4 = -\theta(1)/\theta(2)*x_1 - \theta(0)/\theta(2) + 1/\theta(2);$$

### Tolerancia de margen:

```
T = [];
```

```
for n=1:rows(res.sv_coef)
```

```
if abs(res.sv_coef(n)) == 1000
```

```
T(n) = 1 - sign(res.sv_coef(n))*(theta*X(res.sv_indices(n,:))'+theta0');
```

```
else T(n) = 0;
```

```
endif
```

```
endfor
```

$n=3 \rightarrow \zeta_9 = 2.9986$


$n=5 \rightarrow \zeta_{10} = 0.50113$

Las demás muestras tienen  $\zeta_n = 0$ .

Aquellos vectores cuyas tolerancias de margen  $\zeta$  son diferente de 0, tienen error de clasificación si la tolerancia de margen  $\zeta > 1$  y dentro del margen si  $\zeta \leq 1$ . Por lo tanto los vectores soporte erróneos son las muestras 9 y 10.

### Representación gráfica:

```
plot(X(xl==1),X(xl==1,2),"or",X(xl==2,1),X(xl==2,2),"ob", X(res.sv_indices,1),  
X(res.sv_indices,2),"xb",x1,x2,"-k",x1,x3,"-g",x1,x4,"-g",X([9,10],1), X([9,10],2),"xr");  
axis([0 7 0 7])
```



**2. Realiza un experimento donde se evalúe el error de clasificación en función de los parámetros del clasificador basado en SVM. Mas concretamente, explora los valores del parámetro C (-c 1, 10, 100...) y el tipo de de kernel (-t 0, 1, 2, 3). Para aquellos tipos de kernel que lo permitan, explora sus parámetros específicos. Realiza la exploración de parámetros descrita utilizando un conjunto limitado valores de PCA (D = 50,100,200).**

Para realizar dicho experimento creamos un pca+script svm-exp.m al cual le pasamos distintos valores de de D (dimensiones), C, K (kernel), para el caso del kernel polinomial, le pasamos diferentes valores de G (grado), para el caso del kernel radial y sigmoid diferentes valores de gamma y usamos un 9% de las muestras para entrenar el clasificador y un 1% para test. Obteniendo los siguientes resultados:

Dimension	Kernel	C	Grado	Gamma	Error
50	Lineal	1	-	-	8,333
50	Lineal	10	-	-	8,5
50	Lineal	100	-	-	9,5

50	Polinomial	1	1	-	9,5
50	Polinomial	1	2	-	32,167
50	Polinomial	1	3	-	83,667
50	Polinomial	1	4	-	87
50	Polinomial	1	5	-	87,5
50	Polinomial	10	1	-	8,333
50	Polinomial	10	2	-	7,833
50	Polinomial	10	3	-	50,833
50	Polinomial	10	4	-	81
50	Polinomial	10	5	-	86,167
50	Polinomial	100	1	-	8,667
50	Polinomial	100	2	-	6
50	Polinomial	100	3	-	9
50	Polinomial	100	4	-	59,667
50	Polinomial	100	5	-	78,167
50	Radial	1	-	0,1	3,833
50	Radial	1	-	0,01	8,833
50	Radial	1	-	0,001	18
50	Radial	1	-	0,0001	86,5
50	Radial	1	-	1E-05	87,667
50	Radial	10	-	0,1	4
50	Radial	10	-	0,01	6,5
50	Radial	10	-	0,001	9,5
50	Radial	10	-	0,0001	18
50	Radial	10	-	1E-05	86,5
50	Radial	100	-	0,1	4
50	Radial	100	-	0,01	5,667
50	Radial	100	-	0,001	7,833
50	Radial	100	-	0,0001	9,5
50	Radial	100	-	1E-05	18
50	Sigmoid	1	-	0,1	14,333
50	Sigmoid	1	-	0,01	10,833
50	Sigmoid	1	-	0,001	27,833
50	Sigmoid	1	-	0,0001	87,667
50	Sigmoid	1	-	1E-05	87,667
50	Sigmoid	10	-	0,1	17,333
50	Sigmoid	10	-	0,01	8,833
50	Sigmoid	10	-	0,001	10,833
50	Sigmoid	10	-	0,0001	27,833
50	Sigmoid	10	-	1E-05	87,667
50	Sigmoid	100	-	0,1	18,833
50	Sigmoid	100	-	0,01	8,333
50	Sigmoid	100	-	0,001	8,667
50	Sigmoid	100	-	0,0001	10,833
50	Sigmoid	100	-	1E-05	27,833
100	Lineal	1	-	-	9,167
100	Lineal	10	-	-	9,667
100	Lineal	100	-	-	11,5
100	Polinomial	1	1	-	10,333
100	Polinomial	1	2	-	77,833
100	Polinomial	1	3	-	87,667
100	Polinomial	1	4	-	87,667

100	Polinomial	1	5	-	87,667
100	Polinomial	10	1	-	8,833
100	Polinomial	10	2	-	13,333
100	Polinomial	10	3	-	81
100	Polinomial	10	4	-	87,333
100	Polinomial	10	5	-	87,667
100	Polinomial	100	1	-	9,167
100	Polinomial	100	2	-	6,333
100	Polinomial	100	3	-	44,167
100	Polinomial	100	4	-	83,5
100	Polinomial	100	5	-	86,833
100	Radial	1	-	0,1	4
100	Radial	1	-	0,01	8,667
100	Radial	1	-	0,001	17,167
100	Radial	1	-	0,0001	86,5
100	Radial	1	-	1E-05	87,667
100	Radial	10	-	0,1	4
100	Radial	10	-	0,01	7
100	Radial	10	-	0,001	9,167
100	Radial	10	-	0,0001	17,5
100	Radial	10	-	1E-05	86,5
100	Radial	100	-	0,1	4
100	Radial	100	-	0,01	6,667
100	Radial	100	-	0,001	8,333
100	Radial	100	-	0,0001	9,167
100	Radial	100	-	1E-05	17,5
100	Sigmoid	1	-	0,1	14,167
100	Sigmoid	1	-	0,01	10,333
100	Sigmoid	1	-	0,001	27,333
100	Sigmoid	1	-	0,0001	87,667
100	Sigmoid	1	-	1E-05	87,667
100	Sigmoid	10	-	0,1	17,5
100	Sigmoid	10	-	0,01	8,833
100	Sigmoid	10	-	0,001	10,333
100	Sigmoid	10	-	0,0001	27,333
100	Sigmoid	10	-	1E-05	87,667
100	Sigmoid	100	-	0,1	18,833
100	Sigmoid	100	-	0,01	8,5
100	Sigmoid	100	-	0,001	8,833
100	Sigmoid	100	-	0,0001	10,333
100	Sigmoid	100	-	1E-05	27,333
200	Lineal	1	-	-	8,667
200	Lineal	10	-	-	10
200	Lineal	100	-	-	10,5
200	Polinomial	1	1	-	12,833
200	Polinomial	1	2	-	87,5
200	Polinomial	1	3	-	87,667
200	Polinomial	1	4	-	87,667
200	Polinomial	1	5	-	87,667
200	Polinomial	10	1	-	8,833
200	Polinomial	10	2	-	49,667
200	Polinomial	10	3	-	87,5



200	Polinomial	10	4	-	87,667
200	Polinomial	10	5	-	87,667
200	Polinomial	100	1	-	8,5
200	Polinomial	100	2	-	8
200	Polinomial	100	3	-	79,5
200	Polinomial	100	4	-	87,5
200	Polinomial	100	5	-	87,667
200	Radial	1	-	0,1	4,167
200	Radial	1	-	0,01	8,667
200	Radial	1	-	0,001	17,333
200	Radial	1	-	0,0001	86,5
200	Radial	1	-	1E-05	87,667
200	Radial	10	-	0,1	3,667
200	Radial	10	-	0,01	7,333
200	Radial	10	-	0,001	9,5
200	Radial	10	-	0,0001	17,5
200	Radial	10	-	1E-05	86,5
200	Radial	100	-	0,1	3,667
200	Radial	100	-	0,01	6,5
200	Radial	100	-	0,001	8,667
200	Radial	100	-	0,0001	9,5
200	Radial	100	-	1E-05	17,5
200	Sigmoid	1	-	0,1	13,5
200	Sigmoid	1	-	0,01	10,5
200	Sigmoid	1	-	0,001	27,167
200	Sigmoid	1	-	0,0001	87,667
200	Sigmoid	1	-	1E-05	87,667
200	Sigmoid	10	-	0,1	17,5
200	Sigmoid	10	-	0,01	8,333
200	Sigmoid	10	-	0,001	10,333
200	Sigmoid	10	-	0,0001	27,167
200	Sigmoid	10	-	1E-05	87,667
200	Sigmoid	100	-	0,1	19,333
200	Sigmoid	100	-	0,01	8,833
200	Sigmoid	100	-	0,001	8,5
200	Sigmoid	100	-	0,0001	10,333
200	Sigmoid	100	-	1E-05	27,167

Se puede apreciar que el mínimo error lo obtiene la dimensión 50 con un kernel radial y gamma de 0,1.

**3. Una vez determinado los valores óptimos de los parámetros del clasificador basado en SVM, entrena y evalúa un clasificador final en los conjuntos oficiales MNIST de entrenamiento y test, respectivamente. Discute los resultados obtenidos comparándolos con los obtenidos con el clasificador de mixtura de gaussianas y con los reportados en la tarea MNIST, especialmente los basados en SVM..**

Tomando como base los conjuntos de parámetros óptimos obtenidos en el apartado anterior evaluamos el conjunto de muestra de test:

Dimension	Kernel	C	Grado	Gamma	Error	Intervalos
50	2	1	-	0,1	2,02	[1,744 - 2,296]

Podemos concluir que el porcentaje de error no ha variado respecto al obtenido en el apartado anterior y que es peor comparándolo con el clasificador de mixturas gaussianas (1.62%).

En relación a las tasas de error de la MNIST web (<http://yann.lecun.com/exdb/mnist/>) comprobamos que se acerca a la tasa de error del clasificador de SVM con kernel gaussiano.